

Penguins – Análisis Completo

Equipo 7

Integrantes:

Fajardo Zavala Yendali Viridiana
González Rivas José Rafael
Maldonado Zamora Silvia Viridiana
Olivera Flores Jonathan
Valencia Quiroz Luis Roberto

2026-01-07

Descripción

El dataset “penguins.csv” es un conjunto de datos sobre las mediciones biométricas de pingüinos en las Islas Palmer, Antártida. Contiene 344 registros y 8 variables.

Variables

1. species: Categórica. La especie del pingüino (Adelie, Chinstrap o Gentoo).
2. island: Categórica. La isla de observación (Torgersen, Biscoe o Dream).
3. bill_length_mm: Numérica (float). Longitud del pico en milímetros.
4. bill_depth_mm: Numérica (float). Profundidad del pico en milímetros.
5. flipper_length_mm: Numérica (float). Longitud de la aleta en milímetros.
6. body_mass_g: Numérica (float). Masa corporal en gramos.
7. sex: Categórica. El sexo del pingüino (male o female).
8. year: Numérica (integer). El año de la observación.

PCA


Explorando el dataset

Table 1: Dimensión del conjunto de datos


Métrica	Valor
Número de observaciones	344
Número de variables	8

Table 2: Primeras filas del conjunto de datos


species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex	year
Adelie	Torgersen	39.1	18.7	181	3750	male	2007
Adelie	Torgersen	39.5	17.4	186	3800	female	2007
Adelie	Torgersen	40.3	18.0	195	3250	female	2007
Adelie	Torgersen	NA	NA	NA	NA	NA	2007
Adelie	Torgersen	36.7	19.3	193	3450	female	2007
Adelie	Torgersen	39.3	20.6	190	3650	male	2007




No se identificaron registros duplicados en el conjunto de datos.




Histogramas



Boxplots




Densidad




Comparación por la variable de clasificación: species


Comparación vía box-plot por especie




Comparación vía histograma por especie




Comparación vía densidad por especie





Correlación




El índice de adecuación muestral de Kaiser-Meyer-Olkin (KMO) fue de ****0.7****, lo que indica una adecuación muestral adecuada para la aplicación del Análisis de Componentes Principales.

Prueba de Bartlett

La prueba de esfericidad de Bartlett fue estadísticamente significativa ($\chi^2 = 742.41$, $gl = 6$, $p < 0.001$), lo que indica que la matriz de correlación es adecuada para la aplicación del PCA.

Previo a la aplicación del Análisis de Componentes Principales (PCA), se evaluó la estructura de correlación de las variables. La matriz de correlación de Spearman mostró asociaciones estadísticamente significativas entre las variables ($p < 0.001$). La prueba de esfericidad de Bartlett fue significativa ($\chi^2 = 742.41$, $gl = 6$, $p < 0.001$), indicando que la matriz de correlación difiere de una matriz identidad. Asimismo, el índice de adecuación muestral de Kaiser-Meyer-Olkin (KMO) presentó un valor de 0.70, lo que sugiere una adecuación muestral adecuada. En


conjunto, estos resultados confirman que los datos son apropiados para la aplicación del Análisis de Componentes Principales.




Se observaron correlaciones fuertes entre algunas variables, destacando la asociación positiva entre la longitud de la aleta y la masa corporal ($r = 0.87$, $p < 0.001$).

PCA

Scree plot




Scree plot




Grafica de los primeros dos componentes



Penguins PCA: Gráfica de componentes principales
Varianza explicada por dos componentes: 88.16 %



Penguins PCA: Gráfica de componentes principales
Varianza explicada por dos componentes: 88.16 %





Componentes



3D


file:///C:/Users/usuario/OneDrive/Desktop/Proyecto 2 Diplomado/Penguins/Club_Penguin/pca13d_temp.htm






file:///C:/Users/usuario/OneDrive/Desktop/Proyecto 2 Diplomado/Penguins/Club_Penguin/pca3d_temp.html



PCA 3D — Penguin Species



PCA 3D — Penguin Species



EXTRAS



El Análisis de Componentes Principales permitió reducir la dimensionalidad del conjunto de datos sin pérdida significativa de información. Los dos primeros componentes principales explicaron el 88.2 % de la varianza total, lo que evidencia que la estructura de los datos puede describirse adecuadamente en un espacio bidimensional.

El primer componente principal estuvo asociado principalmente con el tamaño corporal de los pingüinos, integrando variables como la longitud de la aleta, la masa corporal y la longitud del pico. El segundo componente capturó variaciones relacionadas con la morfología del pico, particularmente su profundidad y longitud.

La proyección de los individuos en el espacio definido por los dos primeros componentes mostró una clara diferenciación entre las especies, destacando la separación de la especie Gentoo respecto a Adelie y Chinstrap. Estos resultados concuerdan con las diferencias morfológicas conocidas entre las especies, lo que respalda la validez del análisis realizado.


En conjunto, los resultados indican que el PCA es una herramienta adecuada para explorar y resumir la variabilidad morfológica de los pingüinos, así como para identificar patrones asociados a la clasificación por especie.

T-SNE

Utilizamos T-SNE como otro algoritmo de reducción de dimensionalidad, en el caso de T-SNE recordamos que opera


convirtiendo distancias en probabilidades.

t-SNE Básico




Rtsne

Para el caso de `r` también se tiene una versión de T-SNE particular más optimizada.




#T-SNE 3D



#R T-SNE 3D


Rtsne 3D: Penguins



Exploración de parámetros t-SNE


Aquí podemos ver que se pueden modificar de manera particular los parámetros de T-SNE para poder obtener resultados más

particulares y con variaciones determinadas.



Exploración Rtsne (perplexity y eta)


Lo mismo se puede hacer para R T-SNE.



Modelo Final

Finalmente podemos agarrar la variante con los parámetros que nos parezca que hayan dado el mejor resultado y analizarlos

en particular.



Conclusión

Podemos ver como T-SNE hace un excelente trabajo en separación de grupos, para nuestro caso particular 2 de los


grupos estaban particularmente cerca, pero en T-SNE la distancia entre grupos no tiene significado así que puede ser ignorada.

UMAP

UMAP es nuestra tercera herramienta de reducción de dimensionalidad, aunque similar a T-SNE UMAP tiene varias ventajas sobre T-SNE


mayor velocidad y una mejor conservación de la estructura global de los datos.

UMAP Básico




UMAP via tidymodels

Con la libreria `tydimodels` de `r` podemos hacer UMAP tambien.




3D UMAP



Exploración de Hipereparámetros


De la misma manera que en T-SNE se pueden modificar de manera fina los parámetros del proceso para obtener resultados

muy particulares.



Modelo Final

Nuevamente seleccionamos los parámetros que nos hayan parecido mejores para nuestro modelo final.



Conclusión

UMAP resulto ser más práctico para trabajar nuestro conjunto de datos, además de que durante la manipulación de la manipulación

se obtuvieron agrupaciones muy interesantes que pueden ayudar a sacar interpretaciones y correlaciones de los datos.